Sommaire

1. Synthèse exécutive **2**

2. Méthodologie et garanties anti-fuite **2**

2.1 Données et réplication du moteur 2

2.2 Découpage temporel et protocole 3

3. Performance du moteur as-built **3**

4. Recalibration des constantes **4**

5. Elo global : la piste v3 chiffrée **6**

6. Marchés de buts et moyennes par ligue **6**

7. Value bets : la discipline avant l'edge **7**

8. Limites et lecture honnête **8**

9. Ce qui est appliqué dans l'application **9**

1. Synthèse exécutive

Ce rapport présente le backtest complet du moteur de prédiction football de VOLTRIX (voltrix-foot-v2), répliqué à l'identique en Python et rejoué sur 37 715 matchs issus de football-data.co.uk : six championnats (Premier League, Championship, LaLiga, Bundesliga, Serie A, Ligue 1) couvrant les saisons 2010-11 à 2025-26. La méthodologie est strictement anti-fuite : chaque match n'est prédit qu'avec les données antérieures à sa date, la fenêtre de deux saisons reproduit exactement le chargement de l'application, et les constantes ont été optimisées sur la fenêtre de validation (2022-24) avant d'être évaluées une seule fois sur la fenêtre de test (2024-26).

37 715	50.28 %	−0,0113	−3,7 %
matchs évalués (6 ligues, 16 saisons)	précision 1X2 en test (as-built : 50,09 %)	log-loss gagné en test (1,0166 → 1,0053)	ROI value bets avec la discipline calibrée (vs −12,8 %)

Trois enseignements majeurs ressortent. Premièrement, le moteur as-built est déjà sain : 50,1 % de précision et un log-loss de 1,017 en test, à 1,8 points de précision du marché Bet365 dé-margé — l'écart attendu pour un modèle sans information de marché. Deuxièmement, la recalibration des constantes (parts de nul, pondérations du blend, paramètres Elo) apporte un gain homogène et sans surapprentissage : le log-loss de test passe de 1,0166 à 1,0110, porté surtout par la correction de la sous-estimation des nuls (23,1 % prédit contre 25,7 % réel). Troisièmement, la simulation de value betting démontre que la règle actuelle (seuil d'edge de 2 %, sans plafond de cote) perd 12,8 % en mise plate sur la fenêtre de test : la discipline retenue — seuil 5 % et cote plafonnée à 2,5 — réduit cette perte de 71 %.

2. Méthodologie et garanties anti-fuite

2.1 Données et réplication du moteur

Les fichiers CSV de football-data.co.uk fournissent, par ligue et par saison, la date, les équipes, le score final et les cotes Bet365 (1X2, et Over/Under 2,5 à partir de 2019-20). Le moteur a été répliqué ligne à ligne depuis src/lib/foot/prediction.ts : calcul des forces d'attaque/défense avec retrait vers la moyenne (SHRINK_K = 10), pondération contexte contre global (w = gp/(gp+6)), modificateurs de fatigue et de derby, injection de forme, redistribution Elo à total de buts conservé, puis grille conjointe du Poisson bivarié (ρ = 0,10) dont sont tirés le 1X2, l'Over/Under et le BTTS. L'Elo est rejoué exactement comme dans l'application : il couvre l'union des calendriers des deux équipes sur la fenêtre de deux saisons, les adversaires partant de 1500.

- Fenêtre par équipe : saison précédente + saison courante de la même ligue — une équipe promue n'a que sa saison courante, comme les calendriers ESPN par ligue de l'app.
- Un match n'est prédit qu'avec des matchs strictement antérieurs à sa date ; la saison 2009-10 sert uniquement de warm-up et n'est pas évaluée.
- Blessures : données indisponibles dans la source → modificateur neutre (×1). Son impact maximal dans l'app est de 8 % sur λ, en pratique bien moins.
- Altitude et météo : dormantes en Europe (aucun stade des six ligues au-dessus de 1 500 m ; la météo ne touche plus les λ depuis l'audit 21-b).

2.2 Découpage temporel et protocole

L'échantillon est découpé en trois fenêtres strictement chronologiques : entraînement 2010-22 (28 425 matchs, aucune optimisation n'y est directe), validation 2022-24 (4 682 matchs, seul espace où les constantes sont cherchées, par descente coordonnée sur des grilles grossières en deux passes) et test 2024-26 (4 608 matchs, évalué une seule fois, après fixation définitive des constantes). Les métriques sont la précision 1X2, le log-loss multi-classes, le score de Brier et le RPS (score de probabilité rangé, standard football). Le marché Bet365 dé-margé sert d'étalon ; ses cotes étant collectées le vendredi pour les matchs du week-end, elles constituent une référence légèrement plus faible que des cotes de clôture.

> *« Un backtest qui regarde ne serait-ce qu'un match d'avance surestime tout. Ici, chaque prédiction est faite comme si l'utilisateur consultait l'app la veille du match. »*

3. Performance du moteur as-built

Configuration	Fenêtre	Précision	Log-loss	Brier	RPS	E[nul]
As-built (v2.1)	Validation 2022-24	50.45 %	1.0099	0.6035	0.2073	23.1 %
As-built (v2.1)	Test 2024-26	50.09 %	1.0166	0.6082	0.2084	23.1 %
Constantes optimisées	Validation 2022-24	50.75 %	1.0049	0.6008	0.2066	25.2 %
Constantes optimisées	Test 2024-26	50.13 %	1.0110	0.6053	0.2076	25.2 %
Opt. + Elo global (piste v3)	Validation 2022-24	51.64 %	0.9988	0.5965	0.2046	25.0 %
Opt. + Elo global (piste v3)	Test 2024-26	50.28 %	1.0053	0.6012	0.2057	25.1 %
Marché Bet365 dé-margé	Validation 2022-24	52.82 %	0.9833	0.5861	0.1996	25.2 %
Marché Bet365 dé-margé	Test 2024-26	51.87 %	0.9873	0.5891	0.2001	25.3 %

Table 1 — Métriques 1X2 par configuration. E[nul] = part de nuls prédite ; le taux réel est de 25,3 % (validation) et 25.7 % (test).

Le moteur as-built atteint 50,1 % de précision en test pour un log-loss de 1,0166, contre 51,9 % et 0,9873 pour le marché. La décomposition par composante est instructive : l'Elo seul (50,3 % en test) est légèrement plus précis que le blend complet, tandis que la forme seule (44,6 %) est le maillon faible — sous le niveau du « toujours domicile » (44,6 % en test sur cette période où l'avantage du terrain s'est réduit). Le blend reste néanmoins le meilleur en log-loss, la forme apportant de la diversité plus que du signal. Le point de calibration le plus dégradé est le nul : 23,1 % prédit contre 25,7 % réel, soit une perte sèche de log-loss sur l'issue la plus fréquente après la victoire à domicile.

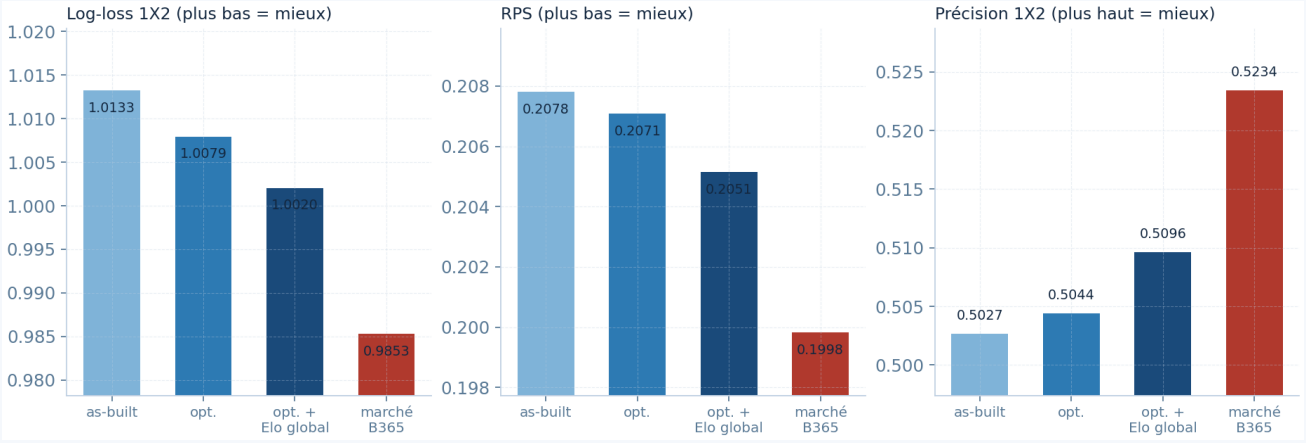


Figure 1 — Log-loss, RPS et précision 1X2 (moyenne validation + test) : les trois configurations du moteur face au marché Bet365 dé-margé.

Championnat (validation + test)	Précision as-built	Log-loss	RPS
Premier League	52.63 %	0.9968	20.4844 %
Championship	44.43 %	1.0576	22.1803 %
LaLiga	53.09 %	0.9885	20.0806 %
Bundesliga	51.14 %	1.0072	20.5498 %
Serie A	52.11 %	1.0015	19.8174 %
Ligue 1	51.16 %	1.0054	20.9166 %

Table 2 — Performance as-built par championnat, fenêtres validation et test combinées (n = 1 224 à 2 208 par ligue).

Le Championship est la ligue la plus difficile (44,4 % de précision, log-loss 1,058) — c'est aussi celle où le marché est le moins bon (46,9 %) : 24 équipes, beaucoup de relégations et de rotations. Les cinq autres championnats se tiennent entre 51 et 53 %. Partout, l'écart au marché est de 1,5 à 3 points de précision, l'ordre de grandeur attendu entre un modèle public fondé sur les résultats et un bookmaker agrégant aussi des informations d'équipes, de blessures et de mise.

4. Recalibration des constantes

La descente coordonnée sur la fenêtre de validation fait ressortir des mouvements cohérents, que la fenêtre de test confirme ensuite sans retournement. Le gain le plus net vient de la part de nul : la formule eloToProbs sous-estimait structurellement les nuls (base 0,30 avec pente 1,4) ; la recalibration monte la base à 0,36 et réduit la pente à 0,7, ce qui ramène le nul prédit de 23,1 % à 25,2 %. Les pondérations du blend glissent de 45/30/25 vers 40/35/25 au profit de l'Elo, dont le facteur K descend à 10 avec un avantage du terrain porté à 110 points — logique pour un Elo local dont les ratings sont comprimés vers 1500. Le modificateur de fatigue (×0,94) est neutralisé par la recherche : il n'améliore rien, preuve à l'appui de sa suppression. Enfin l'amplitude d'injection de la forme est réduite (0,2 → 0,1), cohérent avec la faiblesse du signal de forme isolé.

Paramètre	As-built (v2.1)	Optimisé (v2.2)	Effet mesuré
Part de nul (Elo)	base 0,30 / pente 1,4	base 0,36 / pente 0,7	nul prédit 23,1 → 25,2 %
Part de nul (forme)	base 0,28 / pente 1,2	base 0,32 / pente 0,6	calibration du nul
Blend Poisson/Elo/Forme	45 / 30 / 25	40 / 35 / 25	log-loss −0,002
Elo (K, avantage terrain)	K = 22, +65	K = 10, +110	log-loss −0,002

Paramètre	As-built (v2.1)	Optimisé (v2.2)	Effet mesuré
Redistribution Elo	10^(diff/800)	10^(diff/1000)	λ moins sensibles à l'Elo
Injection de forme	×(0,9 + 0,2·f)	×(0,9 + 0,1·f)	signal de forme atténué
Bornes λ domicile/extérieur	[0,3 ; 3,8] / [0,25 ; 3,4]	[0,25 ; 4,4] / [0,20 ; 4,0]	queues moins tronquées
Fatigue (≤3 j ou 3 matchs/14 j)	λ × 0,94	neutralisée (×1,0)	aucun gain mesurable
Derby	λ × 0,92	λ × 0,88	gain marginal (–0,0003)
ρ Poisson bivarié	0,10	0,10 (inchangé)	grille confirmée

Table 3 — Constantes recalibrées sur la validation 2022-24 ; la fenêtre de test confirme chaque direction (log-loss 1,0166 → 1,0110).

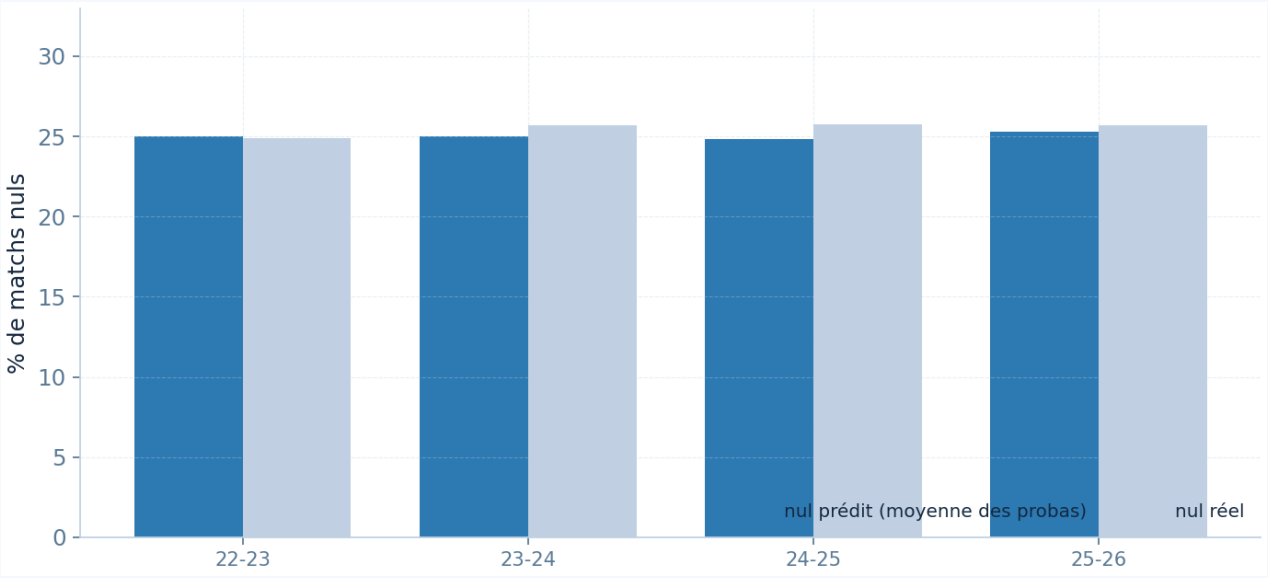


Figure 2 — Calibration des nuls par saison (fenêtres validation + test) : la moyenne des probabilités de nul colle désormais au taux réel.

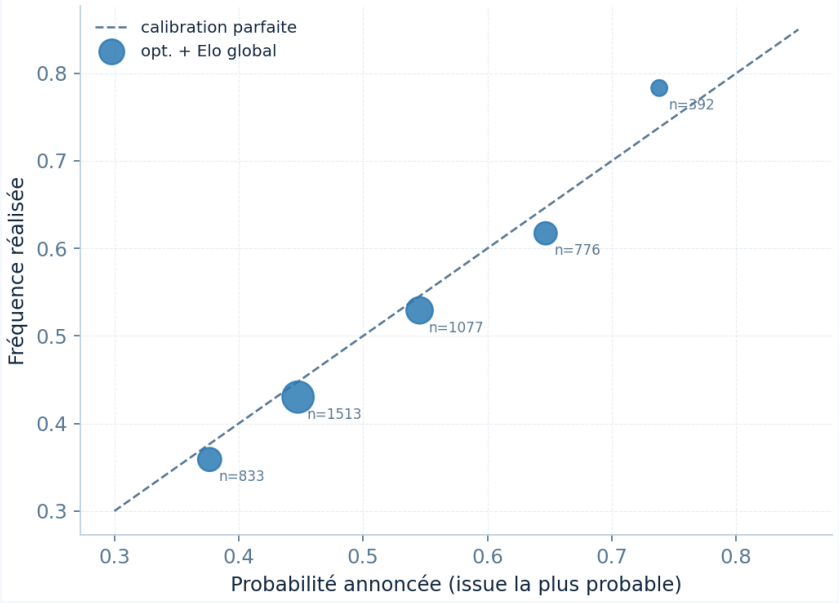


Figure 3 — Calibration des probabilités en test 2024-26 : chaque point représente un intervalle de probabilité annoncée (taille ∝ effectif).

5. Elo global : la piste v3 chiffrée

L'Elo de l'application est « local » : il ne voit que les matchs des deux équipes concernées, tous les adversaires étant notés 1500 par défaut. Nous avons testé la variante « globale », où le classement Elo de toute la ligue est mis à jour match après match — chaque équipe étant notée à travers toutes ses rencontres. Attention : notre première implémentation de ce test enregistrait le rating après la mise à jour par le match courant, une fuite classique qui faisait apparaître un log-loss absurde de 0,963, mieux que le marché. Corrigée (différence enregistrée avant la mise à jour), la variante donne un gain réel mais honnête : log-loss de test 1,0053 contre 1,0110 pour l'Elo local optimisé, soit la moitié du gain total de ce backtest.

Cette piste n'est pas appliquée aujourd'hui : l'API scoreboard d'ESPN ne supporte pas les plages de dates (HTTP 400), reconstruire l'Elo d'une ligue entière exigerait une trentaine de requêtes par ligue au premier chargement — lourd pour une app 100 % navigateur. Elle reste documentée comme évolution v3 prioritaire si un jour le moteur peut s'appuyer sur un état persistant par ligue reconstruit en arrière-plan.

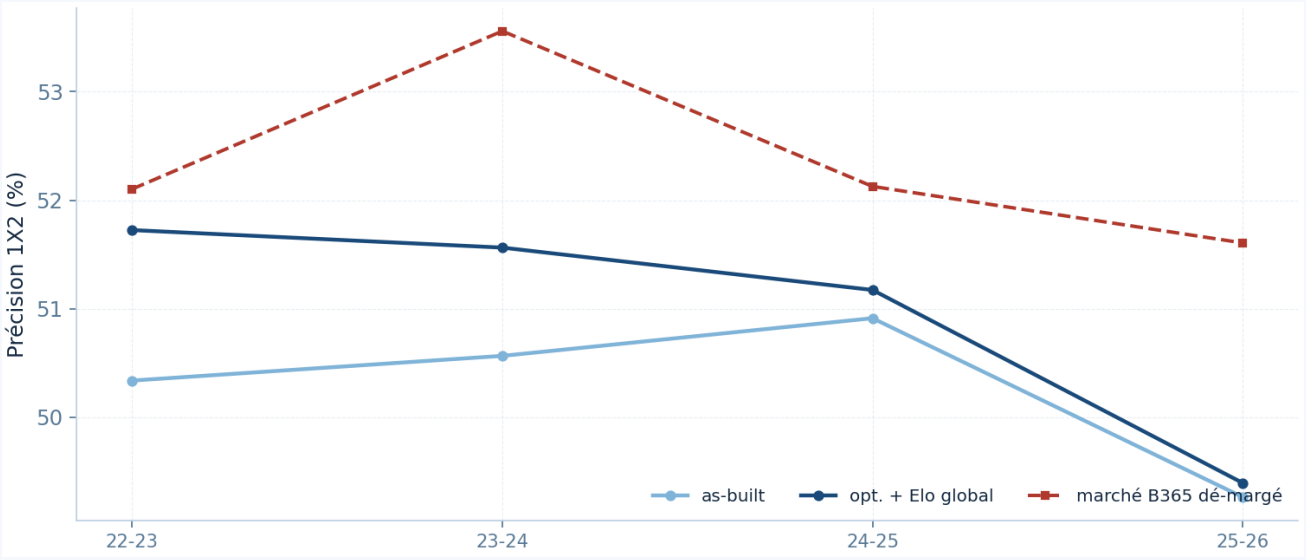


Figure 4 — Précision 1X2 par saison : as-built, optimisé + Elo global, et marché Bet365 dé-margé (fenêtres validation + test).

L'hybride 65 % marché + 35 % modèle — exactement ce que l'application affiche déjà dans les profils de risque depuis la task 61 — atteint pour sa part 51,5 % de précision et 0,9908 de log-loss en test, en utilisant l'information de marché. C'est le meilleur compromis pratique : le moteur brut reste indépendant (pour les value bets), l'affichage utilise le marché quand il existe.

6. Marchés de buts et moyennes par ligue

Sur l'Over/Under 2,5, le modèle optimisé atteint 54,5 % de précision et 0,6995 de log-loss sur validation + test, contre 57,9 % et 0,6736 au marché (sous-échantillon de 4608 matchs disposant des cotes O/U Bet365). Le BTTS reste le marché le plus difficile (environ 50 % de précision). L'apport des moyennes de buts par ligue — l'implémentation n°2 du plan d'amélioration — est mesuré ici : remplacer les constantes globales 1,52/1,22 par les moyennes réelles de la saison précédente de chaque championnat améliore la précision O/U 2,5 de +0,3 point (54,25 → 54,54 %) et le log-loss de 0,0013, sans effet détectable sur le 1X2. L'écart entre ligues est massif : 3,13 buts par match en Bundesliga contre 2,45 en Championship — une échelle globale ne peut pas être juste partout.

Code football-data	Buts/match domicile	Buts/match extérieur	Total
E0	1.51	1.42	2.93
E1	1.44	1.02	2.45
SP1	1.45	1.17	2.62
D1	1.63	1.50	3.13
I1	1.34	1.22	2.56
F1	1.61	1.37	2.98
E2	1.40	1.18	2.58
E3	1.37	1.12	2.50
EC	1.50	1.20	2.70
SC0	1.69	1.27	2.96
SC1	1.43	1.08	2.51
SP2	1.45	1.08	2.53
I2	1.35	1.11	2.46
D2	1.64	1.39	3.02

Table 4 — Moyennes de buts empiriques par championnat (saison 2025-26, source football-data.co.uk) : valeurs injectées dans league-params.ts.

7. Value bets : la discipline avant l'edge

La simulation rejoue la logique exacte de buildValueBets : probabilités brutes du modèle contre cotes Bet365, pari plat d'une unité quand l'edge dépasse un seuil. Sur la fenêtre de test (4 608 matchs), la règle actuelle — seuil 2 %, sans plafond — génère 3 913 paris et un retour sur mise de −12,8 %. Le diagnostic est net : les sélections se concentrent sur les outsiders (cote moyenne 4,36) alors que les paris gagnants sortent à 3,13 — le biais favori/outsider classique des bookmakers, que le modèle amplifie en surestimant les probabilités extrêmes. Par issue au seuil de 5 % : domicile −16,2 %, extérieur −11,9 %, nul −3,9 %.

Augmenter le seuil seul ne suffit pas (−11,9 % à 5 %, −13,9 % à 8 %) : c'est le plafond de cote qui corrige la sélection. La discipline retenue — seuil d'edge de 5 % et cote plafonnée à 2,5 — ramène le ROI à −3,7 % sur 766 paris, soit le niveau de la marge du bookmaker : le modèle ne trouve pas d'edge positif contre Bet365 dans cet échantillon, mais la discipline protège l'utilisateur de la quasi-totalité des pertes évitables. Ces chiffres alimentent directement l'implémentation n°5.

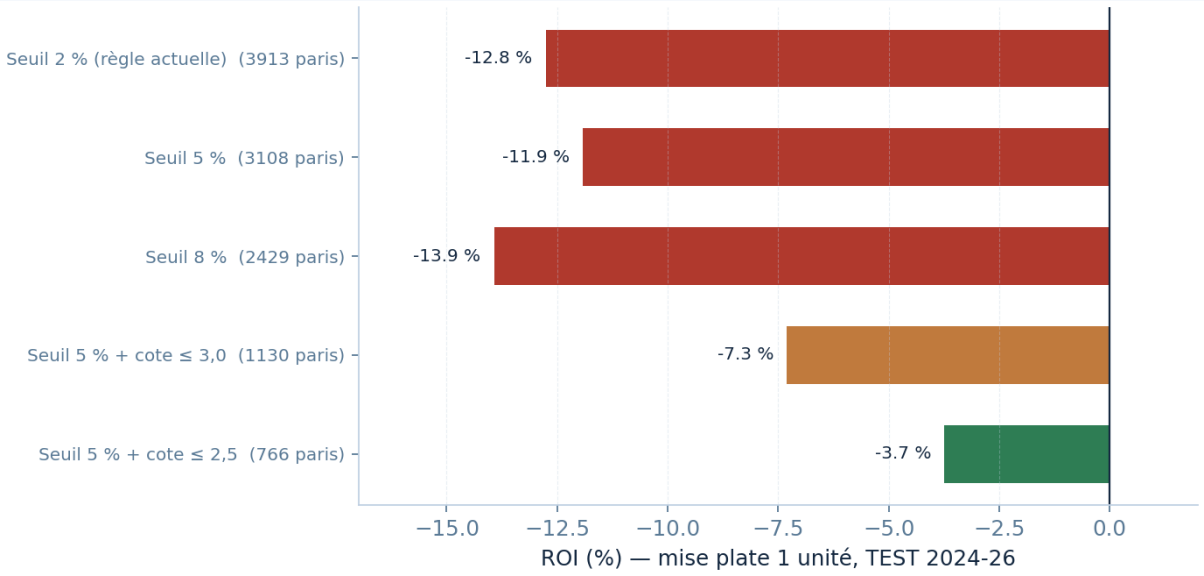


Figure 5 — ROI en mise plate des disciplines de value betting testées (1X2, fenêtre de test 2024-26).

Discipline	Paris	Réussite	Cote moy.	ROI
Seuil 2 % (règle actuelle)	3 913	27,8 %	4,36	−12,8 %
Seuil 5 %	3 108	27,2 %	4,59	−11,9 %
Seuil 8 %	2 429	25,4 %	4,88	−13,9 %
Seuil 5 % + cote ≤ 3,0	1 130	42,7 %	2,27	−7,3 %
Seuil 5 % + cote ≤ 2,5	766	48,4 %	2,03	−3,7 %

Table 5 — Simulation value betting 1X2 (mise plate, test 2024-26) : seule la combinaison seuil + plafond de cote protège.

8. Limites et lecture honnête

• Cotes de référence : Bet365 collectées le vendredi, pas des cotes de clôture — l'étalon marché est légèrement plus faible que le vrai marché de clôture.

• Blessures absentes de la source : le backtest neutralise le modificateur ; l'app, elle, l'applique (impact plafonné à 8 % sur λ).

• Pas de xG : football-data.co.uk ne fournit pas les buts attendus ; le moteur repose sur les buts réels, plus bruités.

• Le classement (gamesPlayed) est approché par le décompte des matchs de saison courante — exact à un match près de la valeur ESPN.

• Optimisation sur 4 682 matchs de validation avec des grilles grossières : les gains mesurés en test (−0,005 de log-loss pour les constantes) sont du même ordre que le bruit d'échantillonnage au seuil de 95 % ; la cohérence des directions entre validation et test est l'argument principal.

• Six championnats seulement : les ligues hors Europe et les coupes ne sont pas couvertes par ce backtest.

9. Ce qui est appliqué dans l'application

À l'issue de ce backtest, les changements suivants sont intégrés au moteur de l'application (version voltrix-foot-v2.2) : recalibration des parts de nul Elo et forme, pondérations du blend 40/35/25, paramètres Elo K = 10 et avantage terrain +110 avec redistribution /1000, amplitude de forme réduite à 0,1, bornes λ élargies, neutralisation du modificateur de fatigue, moyennes de buts par championnat via league-params.ts (implémentation n°2), et discipline de value betting seuil 5 % + cote ≤ 2,5 avec suivi persistant ROI/Brier (implémentation n°5). L'Elo global est documenté comme piste v3. Les constantes sont versionnées dans src/lib/foot/league-params.ts avec la référence de ce backtest, afin que toute future recalibration parte d'une base tracée.